

Construire et piloter la solution ML

De logs nettoyés à un système de priorisation

Durée	2 h 30 à 3 h
Modalité	Travail en groupe — mêmes groupes qu'aux TP précédents
Restitution	Débrief collectif en fin de séance
Outils	Python · pandas · scikit-learn · Git

Contexte

Après le travail de qualification et de nettoyage réalisé au TP 3, les données sont désormais suffisamment exploitables pour construire un premier prototype. La direction souhaite déterminer s'il est possible d'aider les analystes sécurité à prioriser automatiquement les événements qui leur sont transmis.

Votre rôle

Équipe projet Data/ML.

Votre mission

Concevoir et évaluer un prototype de classification permettant de répartir les événements entre NORMAL, SUSPICIOUS et MALICIOUS.

Votre objectif n'est pas uniquement d'obtenir le meilleur score statistique. Vous devez proposer un modèle cohérent avec les conséquences opérationnelles des faux positifs et des faux négatifs.

La cible

Classe	Signification opérationnelle
NORMAL	Événement ne nécessitant pas d'investigation
SUSPICIOUS	Événement nécessitant une vérification humaine
MALICIOUS	Événement associé à un incident confirmé

Ressources fournies

- cleaned_dataset.csv — le dataset consolidé issu du TP 3, enrichi de la colonne cible ;
- data_dictionary.md — description de chaque colonne ;
- starter_notebook.ipynb — squelette de travail (imports et sections, sans solution).

Travail demandé

A. Comprendre la cible

Distribution des classes, ampleur du déséquilibre, données utilisables, données à exclure, risques de fuite de cible.

B. Feature engineering

Plusieurs signaux utiles ne figurent pas directement dans le fichier et doivent être construits : heure de l'événement, échecs récents, compte privilégié, criticité de l'actif, localisation inhabituelle, fréquence d'activité. Cette liste n'est ni imposée ni exhaustive — justifiez vos choix.

C. Construire une baseline (obligatoire)

Avant tout modèle, calculez une baseline naïve — par exemple prédire toujours la classe majoritaire. Sans ce point de comparaison, vos scores ne veulent rien dire.

D. Comparer au moins deux modèles

Par exemple parmi : régression logistique, arbre de décision, forêt aléatoire. Ne présumez pas qu'un modèle plus complexe sera meilleur : vérifiez-le.

E. Évaluer

Matrice de confusion, precision, recall et F1 par classe, macro F1, nombre de faux positifs et de faux négatifs. Comparez systématiquement à la baseline.

F. Relier les métriques au métier

Entre un faux positif et un faux négatif, lequel est le plus grave ici ? Argumentez, puis choisissez votre modèle final en conséquence.

Livrables attendus

- analyse de la cible et des classes ;
- features retenues et justification ;
- baseline ;
- comparaison d'au moins 2 modèles ;
- matrice de confusion + precision / recall / F1 ;
- choix du modèle final argumenté ;
- analyse des faux positifs et faux négatifs ;
- impact métier de la solution ;
- repository Git / notebook ou code reproductible ;
- backlog, planning et Risk Register mis à jour après les incidents.

Point d'attention

Toutes les colonnes du fichier ne sont pas utilisables comme variables d'entrée. Pour chacune, demandez-vous si l'information est réellement disponible au moment où le système doit prioriser un événement qui vient d'arriver. Une colonne qui n'existe qu'après le traitement d'un événement ne peut pas servir à le prédire.